




IMPLEMENTASI ALGORITMA MACHINE LEARNING UNTUK PREDIKSI PERSETUJUAN PINJAMAN

Kelompok E

Group Members

Abnur Afif Al-Ghifari
K1D024003



Cariesa Putra Tsabitha
K1D024034

M. Rafi Abdillah
K1D024018

Alifah Safitri
K1D024015



Intan Vania Saraswati
K1D024014



Latar Belakang

Sektor perbankan menghadapi tantangan dalam mengevaluasi kelayakan pinjaman secara efisien, karena proses manual rentan terhadap subjektivitas dan meningkatkan risiko kredit macet. Oleh karena itu, penelitian ini mengimplementasikan algoritma machine learning pada Loan Approval Prediction Dataset – yang memuat variabel profil peminjam, nilai aset, kondisi keuangan, dan skor CIBIL – untuk membangun model klasifikasi otomatis yang mampu mendukung pengambilan keputusan kredit secara lebih cepat dan berbasis data.



Tujuan

1. Membangun sistem prediksi otomatis yang dapat mengklasifikasikan status persetujuan pinjaman berdasarkan profil peminjam dan data finansialnya.
 2. Membantu lembaga keuangan dalam mengambil keputusan kredit secara lebih cepat dan berbasis data.
 3. Menghasilkan model machine learning yang mampu mengklasifikasikan data secara akurat menggunakan variabel seperti profil peminjam, kondisi finansial, nilai aset, dan skor CIBIL.
- 

Tinjauan Dataset

1

Dataset yang digunakan adalah Loan Approval Prediction Dataset dari Kaggle. Dataset ini dipilih karena permasalahan nyata yang kerap dihadapi lembaga keuangan, yakni menentukan apakah suatu pengajuan pinjaman layak untuk disetujui atau ditolak berdasarkan karakteristik dan kondisi finansial pemohon. Variabel-variabel yang tersedia mencakup profil peminjam, nilai aset, riwayat kredit, hingga skor CIBIL (Credit Information Bureau India Limited), yang mengindikasikan bahwa dataset ini berasal dari konteks perbankan di India.

2

Variabel	Tipe Data	Variabel	Tipe Data
loan_id	Numerik	cibil_score	Numerik
no_of_dependents	Numerik	residential_assets_value	Numerik
education	Kategorikal	commercial_assets_value	Numerik
self_employed	Kategorikal	luxury_assets_value	Numerik
income_annum	Numerik	bank_asset_value	Numerik
loan_amount	Numerik	loan_status	Kategorikal
loan_term	Numerik		

Deskripsi Variabel

Variabel	Deskripsi
Loan_id	Nomor identitas unik untuk setiap pengajuan pinjaman. Kolom ini bersifat sebagai penanda (identifier) dan tidak digunakan sebagai fitur prediktif.
no_of_dependents	Jumlah tanggungan (anggota keluarga) yang menjadi tanggung jawab pemohon.
education	Tingkat pendidikan pemohon, terdiri atas dua kategori: Graduate dan Not Graduate.
self_employed	Status pekerjaan mandiri pemohon, terdiri atas dua kategori: Yes dan No.
income_annum	Pendapatan tahunan (<i>annual income</i>) pemohon.
bank_asset_value	Total nilai aset atau simpanan pemohon pada bank.

Deskripsi	Deskripsi
loan_amount	Jumlah nominal pinjaman yang diajukan oleh pemohon.
loan_term	Jangka waktu pengembalian pinjaman, dinyatakan dalam tahun.
residential_assets_value	Total nilai aset properti tempat tinggal (rumah) milik pemohon.
commercial_assets_value	Total nilai aset properti komersial milik pemohon.
luxury_assets_value	Total nilai aset properti komersial milik pemohon.
cibil_score	Skor kredit (<i>credit score</i>) pemohon yang merepresentasikan riwayat dan kelayakan kredit, dengan rentang nilai sekitar 300–900
loan_status	Status akhir atas pengajuan pinjaman,

Exploratory Data Analysis

Statistika Deskriptif


1. Fitur Numerik

- Beberapa fitur memiliki mean lebih tinggi dari median (outlier)
- Fitur `cibil_score` dan `income_annum` memiliki mean dan median yang hampir sama (distribusi normal)
- Variabel `residential_assets_value` memiliki nilai negatif (hutang)


2. Fitur Kategorik

- Fitur `education` dan `self_employed` memiliki proporsi yang hampir seimbang sempurna.
- Variabel `target loan_status` proporsi Approved sebesar 62,2% dan Rejected sebesar 37,8%

Visualisasi





loan_status
proporsi Approved sekitar 62,2% dan Rejected sekitar 37,8%, data masih tergolong seimbang



income_annum
distribusi pendapatan tahunan pemohon (`income_annum`) terlihat relatif merata pada rentang 200 ribu rupee hingga 9,9 juta rupee

EDA




Boxplot

Pendapatan tahunan pemohon memiliki median sekitar 5,1 juta rupe, sebaran data yang cukup luas, dan tidak ada outlier.

Scatter Plot

Terdapat hubungan positif antara pendapatan tahunan dan jumlah pinjaman.

Heatmap



CIBIL Score memiliki hubungan paling kuat dengan status pinjaman ($r = -0.77$).

Pendapatan tahunan berkorelasi sangat kuat dengan aset mewah ($r = 0.93$).

Validasi Data

- Tidak ada data yang missing value dan duplikat
- Fitur yang outlier :
residential_asset_value (52)
commercial_asset_value (37) dan
bank_asset_value (5)



Pre-processing Data

TUJUAN

Pre-processing dilakukan untuk mempersiapkan data agar siap digunakan dalam proses pemodelan machine learning.

1. Penanganan Outlier

→ Penghapusan Variabel yang Memiliki Makna Sama.

- Drop variabel luxury_assets_value

```
df.drop(columns=['luxury_assets_value'])
```

→ Capping Nilai Ekstrem untuk Variabel residential_assets_value & commercial_assets_value

- dengan mengganti nilai outlier

```
df[col] = np.where(df[col] < lower_bound, lower_bound,  
df[col])
```

```
df[col] = np.where(df[col] > upper_bound, upper_bound,  
df[col])
```

→ Penghapusan Outlier bank_assets_value

- Drop outlier variabel bank_assets_value

```
df = df[(df['bank_asset_value'] >= lower_bank)  
& (df['bank_asset_value'] <= upper_bank)]
```

2. Encoding Variabel Kategorik

→ Label Encoding

- education: Graduate 1 | Not Graduate 0
- self_employed: Yes 1 | No 0
- loan_status (Target): Approved 0 | Rejected 1

```
df[col] = le.fit_transform(df[col])
```



Pre-processing Data

3. Data Scaling

→ Metode 1: Min-Max Normalization

- Mengubah nilai variabel kontinu menjadi rentang 0 sampai 1.

```
df_normalized[kolom_normalisasi] =  
scaler.fit_transform  
(df_normalized[kolom_normalisasi])
```

→ Metode 2: Standarisasi (Z-Score Scaling)

- Mengubah distribusi data agar memiliki rata-rata = 0 dan standar deviasi = 1.

```
df_standardized[kolom_numerik] =  
(df_normalized[kolom_numerik] - mean) / std
```

4. Splitting Data

- 80% data training
- 20% data testing

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
test_size=0.2, random_state=42, stratify=y)
```

- stratify = y agar proporsi kelas target tetap seimbang
- random_state = 42 agar hasil pembagian data konsisten




Pemodelan

Tahap pemodelan dilakukan untuk membangun model klasifikasi yang mampu memprediksi status persetujuan pinjaman berdasarkan karakteristik pemohon. Pada penelitian ini digunakan beberapa algoritma klasifikasi, yaitu Logistic Regression, Decision Tree, Random Forest, dan XGBoost. Selanjutnya, kinerja masing-masing model dibandingkan menggunakan metrik evaluasi untuk menentukan model dengan performa terbaik dalam memprediksi status pinjaman.

Model	Nilai Akurasi
Logistic Regression	0.9332
Decision Tree	0.9859
Random Forest	0.9848
XGBoost	0.9894


Hasil perbandingan menunjukkan bahwa XGBoost memiliki performa terbaik dengan akurasi 98.94%. Tingginya nilai akurasi menunjukkan bahwa model mampu mengklasifikasikan status persetujuan pinjaman dengan sangat baik. Oleh karena itu, XGBoost dipilih sebagai model terbaik untuk tahap optimasi parameter dan evaluasi lanjutan.

FEATURE IMPORTANCE



Berdasarkan Feature Importance, CIBIL Score

merupakan variabel yang paling penting dalam proses klasifikasi, diikuti oleh Loan Term. Hal ini menunjukkan bahwa model lebih banyak memanfaatkan informasi mengenai skor kredit dan karakteristik pinjaman dibandingkan variabel lainnya.



Berbeda dengan Feature Importance yang hanya menunjukkan urutan fitur paling penting, SHAP memberikan informasi yang lebih rinci mengenai bagaimana setiap nilai fitur berkontribusi terhadap prediksi model. Pada grafik ini, warna merah menunjukkan nilai fitur yang tinggi, sedangkan warna biru menunjukkan nilai fitur yang rendah. Selain itu, semakin jauh posisi titik dari nilai nol, semakin besar kontribusi fitur tersebut terhadap hasil prediksi. Terlihat bahwa CIBIL Score merupakan variabel yang paling dominan, diikuti oleh Loan Term, Income Annum, Residential Assets Value, dan Loan Amount.

Evaluasi dan Hasil

Model XGBoost

Kinerja XGBoost (Awal)

Accuracy: 0.9894

Recall [Rejected Class]: 0.9720

Kinerja XGBoost (Tuned)

Accuracy: 0.9906

Recall [Rejected Class]: 0.9783

Perbandingan


Peningkatan Akurasi: 0.0012

Peningkatan Recall [Rejected]: 0.0062

Interpretasi:


Model XGBoost mengalami peningkatan performa meskipun tidak terlalu besar. Proses tuning berhasil membuat model lebih baik dalam mengenali data pada kelas "Rejected", sekaligus tetap mempertahankan tingkat akurasi keseluruhan yang sudah sangat tinggi.

Analisis Overfitting atau Underfitting



Interpretasi:

Model belajar pola data dengan baik sekaligus mampu melakukan generalisasi, tanpa overfitting maupun underfitting.



Presented by
Fauget Group

Thank You!